26 秋软 B 课程报告

项目	内容
组员（姓名 / 学号）	熊思远 / 2023312323 余思成 / 2023311605
复现论文	MASRubric: Auditing Information Flow in Multi-Agent Systems with Failure-Distilled Pitfall Rubrics 2026 年作者提供稿（2026 年 9 月 28 日版本） 论文与代码入口：https://github.com/TonySY2/MASRubric
代码仓库	https://github.com/DECORATOR0/lycheemas-adv2-course 代码版本：初始实验 8635db0；扩测 84f5389；开关对照 3d2a46e 评分 396cf00 版本与运行对应关系见 docs/extension_details.md
提交日期	2026 年 11 月 12 日

一、复现目标

多智能体系统中，一个智能体的中间输出会成为其他智能体的输入。局部的计算错误、事实冲突或遗漏条件可能沿通信边扩散，并在多轮讨论中被重复引用。MASRubric 在消息进入下游之前检查其质量：对能够修正的错误提供反馈，对多次修正仍不合格的消息停止传播，从而控制错误信息在团队中的累积。本文以当前 MASRubric 稿件为复现对象，集成代码沿用 ADv2 命名。[1]

论文的核心贡献是将失败轨迹转化为可复用的错误指标，依据当前任务和角色检索相关指标，并将逐项审计与“反馈修正或拒绝”结合。它控制的是某一次消息是否传播，保留智能体在后续轮次继续产生新消息的能力。

本组的目标有两项：一是复现当前 MASRubric 的 Dynamic-MAS 数学主配置，选取 GSM8K 和 MATH500 两个基准，以另一组同配置运行记录对照当前论文；二是将 ADv2 集成到 LycheeMAS，串联 MASPO 提示词优化、五 Agent 两轮推理和最终汇总，验证模块调用、消息控制及结果记录能够正常运行。

二、方法描述

2.1 论文机制

离线阶段先运行多智能体系统，收集失败轨迹，从其中归纳具有具体触发条件和检查目标的错误指标，并完成清洗与去重。在线阶段根据任务、角色和当前可见上下文选择适用指标，由审核模型检查当前草稿。通过的消息进入正常通信；不通过时，将违规项和反馈送回原角色重生成，直到通过或达到重试上限。论文还提供全局回退，使有效信息不足时仍能继续求解。

固定指标适配保留在线的审计、反馈和阻断结构。指标记录 id、description 和 keywords；每次审计记录草稿、激活指标、违规项与反馈。控制结果含最终 content、decision、retries 和 attempts。拒绝的 content 为 None，原稿只进入审计文件，不进入后续角色的可见上下文。

状态	触发条件	后续动作
Pass	没有超过阈值的违规项	保存通过的最终版本，允许传播
Retry	有违规项，仍有重生成预算	原角色结合具体反馈重新生成并再次审核
Reject	重试预算耗尽仍未通过	阻断该次消息；保留草稿和理由供审计

2.2 关键实现细节

MASPO 在训练划分中的少量问题上改写各角色的提示词，不更新模型权重。候选提示词与当前提示词进行成对评估，分别比较本节点输出、下游输出和最终答案，组合 Local、Lookahead、Global 三类信号；再以坐标式搜索和 beam 保存候选。本次沿用这套优化器，使用同一非思考模型承担执行、比较和提示词提议，搜索深度按小样本可用性实验设置。[2]

团队按 A、B、C、D、E 的顺序执行。A 与 E 是数学求解者，B 分析条件与数量关系，C 负责程序化计算，D 检查前面的推理。A 与 E 共用角色类型，但节点和提示词各自独立，因此是五 Agent、四种角色。选择题中，C 改为逐项核对选项证据。数学任务中，C 的赋值式 Python 由受限 AST 算术解释器实际求值，只开放算术表达式和变量赋值。

优化与正式推理共用两轮执行器。同一角色在两轮中共享提示词；候选提示词变化后，重新计算受影响节点及其后继。测试阶段加载保存的提示词，并启用 ADv2 在推理过程中逐消息审核、反馈修正或阻断；ADv2 执行的是测试时的运行时优化。

2.3 实现参数与差异

集成配置设置 max_retries=1，即初稿之后最多重生成一次，最多审核两版；violation_threshold=0，表示激活指标中出现违规项就不能放行。判官返回结构为 violations 和 feedback；格式错误、未知指标及调用异常进入错误记录。非思考模式通过请求参数 enable_thinking=false 固定。

当前论文的数学主配置采用 AutoGen SelectorGroupChat。Qwen3.5-9B 负责选择下一位发言者，Qwen3-8B 负责角色推理、指标筛选及审核；先检索 20 个候选指标，再选择 1–5 项，通过率阈值为 60%，修订预算为 3。运行配置 max_turns=7 包含初始用户问题，对应最多 6 条角色消息。复现部分核对同配置独立运行，并按各运行保存的原始评分汇总结果。

LycheeMAS 适配采用人工固定指标，替代失败轨迹建池与语义检索；在本次任务上直接挂载全局适用的指标。所有角色都读取完整的已通过消息，便于跨数学与选择题复用；这也避免把拒绝消息转换成数字 0。该接口版本不执行论文的全局回退，final 被拒绝或模型调用失败时将该题记入失败分母。

关闭 ADv2 的对照保留相同团队、已优化提示词及生成参数，将 evaluation_gate 设为 false，跳过消息审核和语义反馈重生成；角色生成、两轮通信顺序及答案评分仍按相同规则执行。

三、适配逻辑

3.1 框架接口与扩展需求

LycheeMAS v0.3 按构建、运行前优化、记忆、执行和运行后处理划分接口。AgentSpec 保存节点角色、提示词和通信前驱，GraphView 提取图结构并写回提示词，注册器按类别和方法名组织算法实现。

接口或组件	现有能力	本任务所需扩展
AgentSpec 与 GraphView	描述节点、前驱和提示词，支持图结构读写	五 Agent 两轮展开及跨轮提示词共享
PreRunOptimizer	以 optimize(graph) 接口接收并返回未编译图	候选提示词的评价需使用两轮执行流程
执行器与运行时控制器	已有节点生成回调；课程分支已有 ADv2 控制器	在角色及 final 输出后调用审核并控制传播
记忆与运行后接口	提供协议及注册入口，部分实现仍为占位	由课程执行层保存本题轮次状态和审计记录

本次基于已有课程分支继续适配。原框架的记忆节点注入及部分运行后组件尚未接通，当前所缺的是把提示词优化、两轮团队执行和逐消息门控连接起来的运行层。

3.2 接入位置与实现关系

代码位置均相对于 src/lychee_mas/。优化器、执行器和控制器按下列方式衔接。

代码位置	实现接口或继承关系	接入职责
plugins/prerun/base.py methods/prerun/maspo/optimizer.py	MASPOOptimizer 提供 optimize 方法，满足 PreRunOptimizer 协议	注册为 pre_run_optimizer/maspo，搜索并保存角色提示词
course/workflow.py	CourseExecutor 继承 CachedExecutor，重写生成与执行方法	构造两轮图；读取可见消息；调用模型及门控
methods/runtime/agentdropout_v2.py	AgentDropoutV2Controller 通过异步 process 接口返回 GateResult	在角色与 final 出口执行审核、重生成及拒绝
course/cli.py	直接构造优化器和控制器，并注入 CourseExecutor	组织优化、提示词加载、测试和结果保存
course/io.py course/data.py	模型调用、数据加载与评分函数	读取题目，发送请求，解析答案并统计结果

MASPO 通过方法满足运行前优化协议，未显式继承该协议类；ADv2 控制器也通过注册与 process 调用接入。课程 CLI 使用注入后的执行器完成优化，再把保存的提示词交给测试团队。

3.3 数据调用流程

数据加载器读取指定数据集的训练划分和测试划分，固定种子抽样并保存题目 ID。训练问题进入 MASPO，得到角色到提示词的映射文件。测试时加载这份映射，为每道题建立独立执行状态。每个节点先构造允许看见的上下文，再生成、审计、必要时修正，最后把通过的结果写回状态。

同一轮中，角色 i 可以读取位于它之前的角色 j<i；第二轮另可读取上一轮中 j≤i 的角色。表中列出的都是通过审核后的最终版本；被拒绝的位置直接省略。

接收者	同轮可见	第二轮另可见的上一轮消息
A	无	A
B	A	A、B
C	A、B	A、B、C
D	A、B、C	A、B、C、D
E	A、B、C、D	A、B、C、D、E

例如，第一轮 B 的初稿被判定计算有误，重生成后通过，则第一轮 C、D、E 及第二轮 B、C、D、E 读取的都是 B 的修正版；如果 B 最终被拒绝，这些接收者均看不到该消息。第二轮 A 仍然只读取上一轮 A。第二轮结束后，final 汇总该轮所有通过的输出，并接受同样的审核。

完整调用链为：训练问题 → MASPO 生成与比较候选 → 保存角色提示词 → 测试问题 → $A_1…E_1$ → $A_2…E_2$ → final → 答案解析与评分。测试阶段每个角色及 final 的出口包含“审计 → 放行 / 反馈重试 / 阻断”。标准答案只用于评分，不进入角色生成或 ADv2 审核请求。最终输出包括答案、评分以及各次审核和修订记录。

3.4 对框架的改动及原因

本次保留 AgentSpec、注册器和 GraphView 等核心接口，新增 course/ 运行层，负责数据抽样、两轮编排、模型调用、ADv2 门控与评分。新增运行层是为了让各模块在同一任务状态下连续执行，并统一保存输出与审计记录。

MASPO 增加执行器注入和优化节点选择，通过 CourseExecutor 评价 A–E 五套角色提示词；两轮同角色节点通过 prompt_source 共享提示词。这样，候选提示词的评价采用与测试一致的通信流程，修改一个角色时也能同步影响第二轮及相关后继。

ADv2 控制器本次直接复用，在新执行层的消息出口调用 process。选择 LangGraph 载体时，将节点元数据和通信关系写入展开图，再通过 compile().ainvoke() 执行。

3.5 主要问题与解决方法

优化与执行的一致性及消息隔离。原单轮执行器无法准确评价最终两轮团队中的提示词效果，拒绝稿或修订前旧稿也可能进入后续上下文。解决方法是统一使用 CourseExecutor，绑定两轮同角

色提示词，并只传播审核通过的最终版本；候选变化后重算受影响节点及后继，用测试检查同轮、跨轮和 final 的消息隔离。

模型输出的预算与完整性。为提示词提议和角色生成分别设置预算，并对截断或缺少必需字段的审核 JSON 提供有限完整性重试。恢复时保留已经完成的题目及其调用记录，只重新执行错误题。具体预算、MATH 第 454 题的恢复及评分复查见 docs/extension_details.md。

四、测试结果

4.1 环境与数据集

集成实验使用 Linux、Python 3.10.19、LangGraph 1.2.20、SymPy 1.14.0 和 vLLM 0.19.1，模型为 Qwen3-8B。初始四项测试及 MATH 百题开关对照在单张 A100-SXM4-40GB 上运行；ARC-Challenge 百题开关对照在同一张 48GB RTX 4090 上运行。执行、提示词提议、比较与审核均关闭思考模式，题目并发数为 8。

论文复现部分比较另一组同配置运行记录与论文采用组，覆盖 GSM8K 的 1,319 题和 MATH500 的 500 题，按各运行保存的原评分汇总结果。集成测试采用以下独立训练与测试划分。

数据集	优化数据来源	测试数据来源	优化 / 测试题数
GSM8K	官方训练集	官方测试集	4 / 20
MATH500	原 MATH 训练集	MATH500	4 / 20、100
ARC-Easy	官方训练集	官方测试集	4 / 20
OpenBookQA	官方训练集	官方测试集	4 / 20
ARC-Challenge	官方训练集	官方测试集	4 / 100

每个数据集从 8 道训练候选题中选 4 道完成 MASPO 优化，训练题与测试题互不重叠。MATH 扩测包含原 20 题，再以 seed=43 从剩余测试题中抽取 80 题；冻结原提示词，对全部 100 题重新推理。ARC-Challenge 独立完成提示词优化后，冻结提示词用于同一套 100 题的开关对照。每项配对均在同一服务器和模型服务上执行，不重复训练。

4.2 功能测试

功能测试检查模块能否正常执行，以及审核结果是否产生预期的传播行为。代表用例如下。

测试用例	实际行为	结果
正确草稿直接通过	4×3=12 被直接放行，未触发重试	通过
错误草稿修订后通过	4+3=7 经反馈改为 4×3=12，执行 Retry→Pass	通过
错误持续存在时阻断	初稿和修订均为 7，执行 Retry→Reject，输出不传播	通过
两轮消息隔离	同轮、跨轮和 final 不读取拒绝稿及修订前旧稿	通过
提示词加载与完整流程	完成提示词加载、两轮推理、审核和评分；初始 80 题及两项百题开关对照均完成	通过

前三个用例使用预设草稿和修订文本，由真实 Qwen3-8B 审核，三条控制路径均通过。初始实验的 17 项工程测试全部通过；扩测版本在两台服务器分别通过 19、19 项测试，并分别通过 8/8 个非思考并发请求。最终评分版本另通过 29 项本地回归测试及 Ruff 检查。测试记录和各用例输入输出见 evidence/validation/。

4.3 指标对比与结果分析

论文复现将另一组同配置运行记录与当前论文的 Dynamic-MAS + MASRubric 结果对照，准确率如下。

基准	论文采用组	同配置复现记录	差值
GSM8K	1209 / 1319 = 91.66%	1213 / 1319 = 91.96%	+0.30 个百分点
MATH500	398 / 500 = 79.60%	387 / 500 = 77.40%	−2.20 个百分点

同配置复现结果中，GSM8K 比论文采用组高 0.30 个百分点，MATH500 低 2.20 个百分点。结果来源与配置见 evidence/reproduction/。

初始四项集成测试的准确率如下。这批测试用于检查提示词加载、两轮推理、消息门控和评分能否连续执行。

数据集	正确 / 测试	准确率
GSM8K	16 / 20	80%
MATH500	15 / 20	75%
ARC-Easy	18 / 20	90%
OpenBookQA	19 / 20	95%

扩大测试对 MATH500 与 ARC-Challenge 进行同题开关对照，保持各自的模型服务、题目、冻结提示词和生成参数一致。差值按启用 ADv2 减去关闭 ADv2 计算。

数据集	启用 ADv2	关闭 ADv2	准确率差值
MATH500	79/100（79%）	75/100（75%）	+4 个百分点
ARC-Challenge	91/100（91%）	91/100（91%）	0 个百分点

MATH500 在本次 100 题中提高 4 个百分点；ARC-Challenge 两组准确率相同。MATH500 中仅开启组答对 4 题、仅关闭组答对 0 题；ARC-Challenge 中仅开启组答对 2 题、仅关闭组答对 2 题。数学结果按统一等价规则复评，原输出、旧评分和逐题变更均保存，具体记录见 docs/extension_details.md。

结果分析结合代表案例：ARC-Easy 的 MEA_2013_8_2 题中，D 的初稿论证“食物分解释放能量”，却选择“移除废物”；审核指出答案与论证不一致，修订为标准选项 B 后通过。GSM8K 第 54 题中，审核器误解“三倍”的参照对象，将正确初稿 40 引向错误答案 55，团队最终也回答 55。

审核能够触发修订和阻断，也可能引入误判。百题对照同时呈现最终准确率与逐题变化，完整审核统计、调用成本和复查记录保存在仓库中。

五、团队分工与贡献

组员	负责内容	对应产出
熊思远 2023312323	方法原理、适配方案与实现细节	ADv2 核心机制与差异分析；两轮信息流、接口和代码改动说明；复现结果解释
余思成 2023311605	运行环境、实验操作与结果整理	模型服务与数据划分配置；实验运行流程、日志和结果表整理；仓库安装运行说明

附录

仓库资料索引

公共仓库：https://github.com/DECORATOR0/lycheemas-adv2-course。以下路径均相对于仓库根目录。

资料	位置
安装、运行和关键参数	README.md；docs/extension_details.md
代码接入与信息流	docs/architecture.md
数据来源和选题	evidence/data/SOURCES.md；results/各数据集/selection.json
论文复现记录与复算	evidence/reproduction/README.md
逐题输出、调用成本和复查	results/各数据集/；docs/extension_details.md
功能测试与案例	evidence/validation/

参考文献

[1] MASRubric: Auditing Information Flow in Multi-Agent Systems with Failure-Distilled Pitfall Rubrics. 2026 年作者提供稿，2026 年 9 月 28 日版本，第 6 页表 1 与第 4.1 节。论文与代码入口：https://github.com/TonySY2/MASRubric

[2] MASPO: Joint Prompt Optimization for LLM-based Multi-Agent Systems. arXiv:2605.06623, 2026. https://arxiv.org/abs/2605.06623

[3] LycheeMAS 项目，LycheeMASv0.3 分支. https://github.com/ecoli-hit/LycheeMAS

[4] Cobbe K, et al. Training Verifiers to Solve Math Word Problems. arXiv:2110.14168, 2021. GSM8K: https://github.com/openai/grade-school-math

[5] Hendrycks D, et al. Measuring Mathematical Problem Solving With the MATH Dataset. arXiv:2103.03874, 2021. MATH500: https://huggingface.co/datasets/HuggingFaceH4/MATH-500

[6] 刘学博. 高效可控多智能体课程讲义，AgentDropoutV2 相关内容见第 80–82、159–162 页。