26 秋软 B 课程报告

项目	内容
组员（姓名 / 学号）	熊思远 / 2023312323 余思成 / 2023311605
复现论文	AgentDropoutV2: Optimizing Information Flow in Multi-Agent Systems via Test-Time Rectify-or-Reject Pruning Yutong Wang, Siyuan Xiong, Xuebo Liu, Wenkang Zhou, Liang Ding, Miao Zhang, Min Zhang 2026， arXiv:2602.23258v1
代码仓库	https://github.com/DECORATOR0/lycheemas-adv2-course 代码版本：8635db0c51a6d07a6d67707b0b5480d50ad87fc1
提交日期	2026 年 11 月 12 日

一、复现目标

多智能体系统中，一个智能体的中间输出会成为其他智能体的输入。局部的计算错误、事实冲突或遗漏条件可能沿通信边扩散，并在多轮讨论中被重复引用。AgentDropoutV2 在消息进入下游之前检查其质量：对能够修正的错误提供反馈，对多次修正仍不合格的消息停止传播，从而控制错误信息在团队中的累积。[1]

论文的核心贡献是将失败轨迹转化为可复用的错误指标，依据当前任务和角色检索相关指标，并将逐项审计与“反馈修正或拒绝”结合。它控制的是某一次消息是否传播，保留智能体在后续轮次继续产生新消息的能力。

本组完成部分复现与框架适配。复现部分选取 GSM8K 和 MATH500 两个数学基准，回收完整主实验记录并按原运行评分字段复算，与论文 v1 的对应指标对照。适配部分在 LycheeMAS 的接口上接入固定指标 ADv2，并将 MASPO 提示词优化、五 Agent 两轮推理和最终汇总串成可执行流程。目标是验证模块能够在框架内调用、消息流符合设定、结果与审计轨迹能够复查。

二、方法描述

2.1 论文机制

离线阶段先运行多智能体系统，收集失败轨迹，从其中归纳具有具体触发条件和检查目标的错误指标，并完成清洗与去重。在线阶段根据任务、角色和当前可见上下文选择适用指标，由审核模型检查当前草稿。通过的消息进入正常通信；不通过时，将违规项和反馈送回原角色重生成，直到通过或达到重试上限。论文还提供全局回退，使有效信息不足时仍能继续求解。

固定指标适配保留在线的审计、反馈和阻断结构。指标记录 id、description 和 keywords；每次审计记录草稿、激活指标、违规项与反馈。控制结果含最终 content、decision、retries 和 attempts。拒绝的 content 为 None，原稿只进入审计文件，不进入后续角色的可见上下文。

状态	触发条件	后续动作
Pass	没有超过阈值的违规项	保存通过的最终版本，允许传播
Retry	有违规项，仍有重生成预算	原角色结合具体反馈重新生成并再次审核
Reject	重试预算耗尽仍未通过	阻断该次消息；保留草稿和理由供审计

2.2 MASPO 与两轮团队

MASPO 在训练划分中的少量问题上改写各角色的提示词，不更新模型权重。候选提示词与当前提示词进行成对评估，分别比较本节点输出、下游输出和最终答案，组合 Local、Lookahead、Global 三类信号；再以坐标式搜索和 beam 保存候选。本次沿用这套优化器，使用同一非思考模型承担执行、比较和提示词提议，搜索深度按小样本可用性实验设置。[2]

团队按 A、B、C、D、E 的顺序执行。A 与 E 是数学求解者，B 分析条件与数量关系，C 负责程序化计算，D 检查前面的推理。A 与 E 共用角色类型，但节点和提示词各自独立，因此是五 Agent、四种角色。选择题中，C 改为逐项核对选项证据。数学任务中，C 的赋值式 Python 由受限 AST 算术解释器实际求值，只开放算术表达式和变量赋值。

优化与正式推理共用两轮执行器。角色提示词在两轮中共享，改变某个角色的提示词后，重新计算受影响节点及其后继，包含第二轮中的同一角色。优化阶段评估团队输出；测试阶段加载保存的提示词，再在消息出口启用 ADv2。训练问题用于选择提示词，测试问题只用于最终执行和评分。

2.3 实现参数与差异

集成配置设置 max_retries=1，即初稿之后最多重生成一次，最多审核两版；violation_threshold=0，表示激活指标中出现违规项就不能放行。判官返回结构为 violations 和 feedback；格式错误、未知指标及调用异常进入错误记录。非思考模式通过请求参数 enable_thinking=false 固定。

论文主实验复现采用归档中的原始代码、提示词和评分结果，其配置差异在第四节逐项列明。LycheeMAS 适配采用人工固定指标，替代失败轨迹建池与语义检索；在本次任务上直接挂载全局适用的指标。所有角色都读取完整的已通过消息，便于跨数学与选择题复用；这也避免把拒绝消息转换成数字 0。该接口版本不执行论文的全局回退，final 被拒绝或模型调用失败时将该题记入失败分母。

本次集成实验使用 Linux、Python 3.10.19、LangGraph 1.2.20 与 SymPy 1.14.0。模型服务为 vLLM 0.19.1，在一张 A100-SXM4-40GB 上加载 Qwen3-8B，上下文上限 16,384 token、最大服务序列数 16。执行、提示词提议、比较和审核均使用这一模型并关闭思考；客户端按题并发 8。角色生成在优化阶段上限为 1,024 token，测试阶段 MATH 为 2,048，其余为 1,024；各 benchmark 依次运行。

三、适配逻辑

3.1 框架现状与接入位置

LycheeMAS v0.3 以 AgentSpec 保存节点角色、system_prompt 和 predecessors，以注册器按方法名选择实现，提供构建、运行前、记忆、执行和运行后五类接口。接口声明与算法实现分别放在 plugins/ 和 methods/，执行端通过异步回调调用模型。已有模块为本次适配提供了图结构、提示词写回与运行时控制的基础。

接口或扩展点	原有能力	本次使用或补充
build_langgraph AgentSpec / GraphView	静态团队、前驱关系和节点元数据	构造五 Agent 的两轮展开图，保存角色提示词映射
optimize_langgraph MASPOOptimizer	提示词 optimize / apply；多粒度比较与搜索	共用两轮执行器评估候选；产物加载回测试团队
指标配置与运行器	实践分支已有运行前配置与运行时控制的分层	课程 CLI 装载固定指标和重试参数，直接构造控制器
runtime_controller AgentDropoutV2Controller	逐消息 Pass / Retry / Reject	在每个角色和 final 的出口执行门控
attach_memory 运行后优化接口	协议与注册入口；部分算法仍为显式占位	使用本任务的轮次状态；审计轨迹可作为后续模块输入

原框架中的接口存在不等于具体算法已完成。所检查的 v0.3 源码中，attach_memory 的节点注入入口仍会抛出 NotImplementedError；运行后归因、信用分配与部分训练方法也保留显式占位。本次独立仓库只保留必要的类型、注册器、GraphView、MASPO 和 ADv2 模块，再增加课程运行层。它管理任务内的本轮及上一轮状态，不依赖这些尚未接通的组件。

3.2 数据与调用流程

数据加载器读取指定数据集的训练划分和测试划分，固定种子抽样并保存题目 ID。训练问题进入 MASPO，得到角色到提示词的映射文件。测试时加载这份映射，为每道题建立独立执行状态。每个节点先构造允许看见的上下文，再生成、审计、必要时修正，最后把通过的结果写回状态。

同一轮中，角色 i 可以读取位于它之前的角色 $j<i$；第二轮另可读取上一轮中 $j\le i$ 的角色。表中列出的都是通过审核后的最终版本；被拒绝的位置直接省略。

接收者	同轮可见	第二轮另可见的上一轮消息
A	无	A
B	A	A、B
C	A、B	A、B、C
D	A、B、C	A、B、C、D
E	A、B、C、D	A、B、C、D、E

例如，第一轮 B 的初稿被判定计算有误，重生成后通过，则第一轮 C、D、E 及第二轮 B、C、D、E 读取的都是 B 的修正版；如果 B 最终被拒绝，这些接收者均看不到该消息。第二轮 A 仍然只读取上一轮 A。第二轮结束后，final 汇总该轮所有通过的输出，并接受同样的审核。

调用链为：训练问题 → MASPO 生成与比较候选 → 保存角色提示词 → 测试问题 → A_1…E_1 → A_2…E_2 → final → 答案解析与评分。每个角色出口都包含“审计 → 放行 / 反馈重试 / 阻断”。gold 保存在评分对象中，不进入角色生成或 ADv2 判官请求。不同题之间并发，同一题内保持设定顺序。

3.3 代码改动与主要问题

新仓库将所需 LycheeMAS 核心模块作为独立子集保留。主要修改 MASPO 的执行器注入和角色共享映射；新增 course 运行层，负责两轮图、固定指标、数据抽样、模型接口和评分。ADv2 控制器由 CLI 装载固定指标后构造，CourseExecutor 在消息出口调用 process。选择 LangGraph 载体时，展开图注册 AgentSpec metadata 并经 compile().ainvoke() 执行。

文件或模块	变更	作用
course/workflow.py	新增	两轮通信、共享提示词、消息门控、算术工具与图执行
course/cli.py	新增	优化与测试流程、并发、恢复、全分母汇总
course/io.py、data.py	新增	非思考 HTTP 调用、逐题数据与评分
methods/prerun/maspo/	修改	保留多粒度比较与搜索，注入两轮执行器
methods/runtime/ agentdropout_v2.py	复用	严格审计、有限重生成和拒绝控制
tests/test_course.py	新增	通信隔离、提示词共享、工具、解析与恢复检查

第一处问题是优化与执行的一致性及拒绝消息隔离。单轮执行器会使候选提示词的评价流程与最终两轮运行不同；空输出进入旧数字提取逻辑又可能变为默认值 0。为此，MASPO 候选评估与最终运行共用 CourseExecutor，两轮对应节点绑定同一角色提示词；上下文仅由 accepted 状态构

造，拒绝输出保持 None。候选变化沿实际时空连接传播，下游、跨轮缓存与 final 复用同一过滤规则，并由测试检查拒绝稿和修正前旧稿不进入后续提示词。

第二处问题是模型输出预算与完整性：MATH 首次提示词提议达到 1,536 token 上限而中止；增加独立提议预算至 3,072 后完成优化。随后测试出现 1,024 token 截断，因此复用已完成的提示词，以 2,048 token 统一重跑全部 20 题。对仍未完整结束的文本或 JSON，客户端最多追加两次简短格式重试；重试不加入标准答案，失败响应和成本全部保留。

四、测试结果

4.1 论文主实验复算

复现结果来自从原实验服务器迁移保留的完整主运行。按同一次主配置读取逐题评分字段，对 GSM8K 的 1,319 题和 MATH500 的 500 题分别计数，不跨运行拼题。两项结果属于已完成的历史主实验，本次完成了记录回收、配置核对和重新聚合。

基准	论文 v1	本组主运行	差值
GSM8K	91.74%	1209 / 1319 = 91.66%	−0.08 个百分点
MATH500	78.40%	398 / 500 = 79.60%	+1.20 个百分点

执行模型均为 Qwen3-8B。论文 v1 使用 GPT-4.1-mini 选择器、直接选择 top-5 指标与 pass 阈值 100%；归档主配置使用 Qwen3.5-9B 选择器、rerank top-20 后选择 1–5 项与 pass 阈值 60%。因此，两项结果达到论文对应基准的相近水平，但数值差异同时受到选择器、指标选择及阈值设置的影响。归档中的九月论文快照记录 91.66% 与 79.60%，与此次重新聚合一致。

4.2 组合适配可用性

本次实验为每个 benchmark 使用 4 道训练划分问题优化提示词，再执行预先抽取的 20 道测试题。GSM8K 使用官方 train/test；MATH 使用原始 7500 题训练集与 MATH500 测试集；ARC-Easy 与 OpenBookQA 使用官方训练和测试划分。先固定抽出 8 道训练候选题，再从中选 4 道用于优化；各次抽样种子均为 42，实际题号保存在 selection.json。测试题与优化题的 ID 和规范化题面均不重叠。四项测试均以 LangGraph 编译执行。

数据集	优化题数	测试题数	完成 / 正确	审计行为
GSM8K	4	20	20 完成 / 16 正确 80%	重试 2；阻断 2 修订后通过 0
MATH500	4	20	20 完成 / 15 正确 75%	重试 11；阻断 5 修订后通过 6
ARC-Easy	4	20	20 完成 / 18 正确 90%	重试 14；阻断 11 修订后通过 3
OpenBookQA	4	20	20 完成 / 19 正确 95%	重试 35；阻断 27 修订后通过 8

最终题目结果中记录 62 次反馈重试，其中 17 条消息在修订后通过，45 条消息最终被阻断。GSM8K 的提示词变化角色为 E；MATH500 的提示词变化角色为 C；ARC-Easy 的提示词变化角色为 D；OpenBookQA 保留初始提示词。优化后提示词通过实际运行快照与角色输出记录确认已加载。

MATH 最终 20 题按统一数学等价规则离线重评分。题 279 的模型输出为 7π，标准答案为 7\pi；将 Unicode π 与 LaTeX π 归一后，该题从格式误判修正为正确，最终为 15/20。原模型输出不变，旧评分与逐题变更保存在 rescore_audit.json，可由 rescore_math.py 复算。

GSM8K 测试题 54 提供了一个审核误判实例：A 与第二轮 A 的初稿均正确得到 7+3×7+12=40，但判官把“三倍”的参照对象误解成 12，反馈引导模型改成 55 后再拒绝；团队最终也回答 55。两条消息确实被阻断，说明门控路径生效，同时说明同一 8B 模型的审核判断也可能出错，不能把拒绝次数直接等同于成功拦截错误的次数。

按标准答案复核，ARC-Easy 三条“修订后通过”分别为一条由错改对、一条由对改错、一条保持正确；OpenBookQA 八条中，两条改为标准选项，五条保持标准选项，一条质疑题设后改为非选项文本。MATH 六条中，一条由对改错、两条保持正确、三条仍然错误。因此，“修订后通过”表示判官接受，不能直接解释为答案已修正。

4.3 功能测试与结果分析

检查内容	验证方式	结果
确定性工程测试	时空前驱、共享提示词、消息隔离、恢复、输出格式、数学等价评分与执行器等价	17 项通过
真实模型控制分支	人为构造三组草稿及修订，真实 Qwen3-8B 审核 Pass / Retry→Pass / Retry→Reject	3/3 通过
真实服务非思考并发	8 个同时请求；检查答案、返回内容和思考字段	8/8 通过
完整组合流程	MASPO 保存提示词后，由 StateGraph 执行两轮 ADv2 团队	见四项实测

服务器上的 17 项确定性测试全部通过，其中原生 LangGraph 测试实际调用 compile().ainvoke()，并逐节点比较 GraphView 执行器的输入、输出与审计记录。真实判官分支探针另使用 5 次模型审核覆盖三条控制路径，返回内容均未截断；该探针的草稿和修订文字是预设的。benchmark 运行中的反馈修订由模型实际生成，单独记录在各题 attempts 中。

上述两类测试回答不同问题：历史主运行用于核对论文任务上的准确率；本次小规模测试用于确认提示词优化产物、两轮通信、运行时门控和结果落盘能够连续工作。集成测试保留固定测试子集及完整失败记录，准确率按全部抽样题数计分。运行期间的错误、修正与拒绝均从轨迹统计，不以最终答对替代接口行为检查。

五、团队分工与贡献

组员	负责内容	对应产出
熊思远 2023312323	方法原理、适配方案与实现细节	ADv2 核心机制与差异分析；两轮信息流、接口和代码改动说明；复现结果解释
余思成 2023311605	运行环境、实验操作与结果整理	模型服务与数据划分配置；实验运行流程、日志和结果表整理；安装运行附录

附录

A 安装与运行

仓库 README 给出最短运行路径。实验客户端通过 OpenAI 兼容 HTTP 服务调用模型，服务端和客户端可分开部署。先完成安装与确定性测试，再准备数据、优化提示词并运行测试。

```
python -m pip install -e ".[graph,data,dev]"
python -m unittest discover -s tests -v
python scripts/run_course.py --phase both --benchmark gsm8k --train-file
evidence/data/gsm8k_train.jsonl --test-file evidence/data/gsm8k_test.jsonl --output
runs/gsm8k --base-url http://127.0.0.1:8000/v1 --model Qwen3-8B --train-n 4 --eval-n
20 --concurrency 8 --engine langgraph
```

各 benchmark 依次运行，以便复用同一模型服务；每个 benchmark 内的不同测试题可并发。中断后使用原输出目录恢复，程序读取已落盘题号并跳过已完成题；配置不一致时应另建输出目录。

B 关键参数

参数	本次设置	含义
角色 / 推理轮数	5 / 2	十次角色生成后进入 final
MASPO depth / beam	1 / 2	小批次提示词搜索
Local / Lookahead / Global	0.4 / 0.4 / 0.2	多粒度成对比较权重
max_retries / threshold	1 / 0	最多重生成一次，激活指标零容忍
seed / concurrency	42 / 8	固定抽样；不同题并发
max_tokens	1024 / 2048	优化为 1024；MATH 测试为 2048，其余测试为 1024
proposal_max_tokens	1536 / 3072	MATH 提议为 3072，其余为 1536；与角色生成预算分离
格式重试上限	2	仅对不完整输出追加；与 ADv2 语义反馈重试分开

C 产物与复查

产物	复查内容
config.json、selection.json	最终参数、训练题号与测试题号
prompts.json、prompts_stats.json	优化后的角色提示词与搜索统计
evaluation_prompts.json	测试实际使用的提示词快照，恢复时逐项核对
results.jsonl、summary.json	逐题答案、评分、门控记录与完整分母汇总
calls.jsonl	实际模型请求、响应、token 与用途
evidence/reproduction/	历史主运行和独立重复的全量评分摘录、配置与复算脚本
evidence/validation/	环境、确定性测试与真实判官控制分支探针

各数据集优化与测试阶段的调用成本如下，包含已保存的失败和恢复尝试。

数据集或尝试	调用数	输入 token	输出 token
GSM8K	1234	764,829	114,851
MATH500	1280	1,204,707	192,806
ARC-Easy	866	479,610	77,499
OpenBookQA	1028	586,089	97,393
MATH 初次优化中止	314	227,594	48,991
MATH 旧 1024 测试	459	594,539	73,537

四项流程及保留的 MATH 未完成尝试合计 5,181 次模型调用，输入 3,857,368 token，输出 605,077 token，达到输出长度上限 5 次。MATH 正式流程计入一次已完成优化的 790 次调用，以及 2,048 token 测试中包含失败和恢复的全部 490 次调用。另计初次中止优化 314 次和旧 1,024 token 测试 459 次，不重复计算复用的优化。

主实验复算脚本逐行读取已保留的原始评分结果，输出分子、分母、准确率和配置说明；独立重复按同样方式读取。集成实验以每题的 task_id 对齐结果和事件，先检查是否正常完成，再查看各角色的通过、重试和拒绝路径，最后核对最终答案与评分。所有题目都保留在统计分母中。

另外保留一份 2026 年 7 月 11 日的独立 GSM8K 重复运行，结果为 1213/1319=91.96%。它沿用主配置，覆盖全部题号，无重复或缺失；正文采用四月同批主运行作为对照。复算文件为 evidence/reproduction/gsm8k_repeat2.jsonl，配置与运行编号见同目录 summary.json。

D 参考文献

[1] Wang Y, Xiong S, Liu X, Zhou W, Ding L, Zhang M, Zhang M. AgentDropoutV2: Optimizing Information Flow in Multi-Agent Systems via Test-Time Rectify-or-Reject Pruning. arXiv:2602.23258v1, 2026. https://arxiv.org/abs/2602.23258v1

[2] MASPO: Joint Prompt Optimization for LLM-based Multi-Agent Systems. arXiv:2605.06623, 2026. https://arxiv.org/abs/2605.06623

[3] LycheeMAS 项目，LycheeMASv0.3 分支. https://github.com/ecoli-hit/LycheeMAS

[4] Cobbe K, et al. Training Verifiers to Solve Math Word Problems. arXiv:2110.14168, 2021. GSM8K: https://github.com/openai/grade-school-math

[5] Hendrycks D, et al. Measuring Mathematical Problem Solving With the MATH Dataset. arXiv:2103.03874, 2021. MATH500: https://huggingface.co/datasets/HuggingFaceH4/MATH-500

[6] 刘学博. 高效可控多智能体课程讲义，AgentDropoutV2 相关内容见第 80–82、159–162 页。